

Calibration error (x100, Platt scaling)

40  
35  
30  
25  
20  
15  
10  
5  
0

30

40

50

60

70

80

Q&A accuracy

Llama 2 7B

Falcon 7B

Falcon 40B

Yi 6B

Llama 2 70B

Mistral 7B

SOLAR 10.7B

Llama 3.0 8B

Llama 3.1 8B

Mixtral 8x7B

GPT-3.5 Turbo

Yi 34B

Llama 3.1 70B

Llama 3.0 70B

GPT-4o

