

Calibration error (x100, Platt scaling)

40
35
30
25
20
15
10
5
0

Falcon 40B

Llama 3.0 8B

Llama 3.1 8B

Mistral 7B

Yi 6B

Yi 34B

GPT-3.5 Turbo

Llama 2 70B

Llama 3.1 70B

Falcon 7B

Mixtral 8x7B

Llama 3.0 70B

GPT-4o

SOLAR 10.7B

Llama 2 7B

Q&A accuracy

30

40

50

60

70

80

